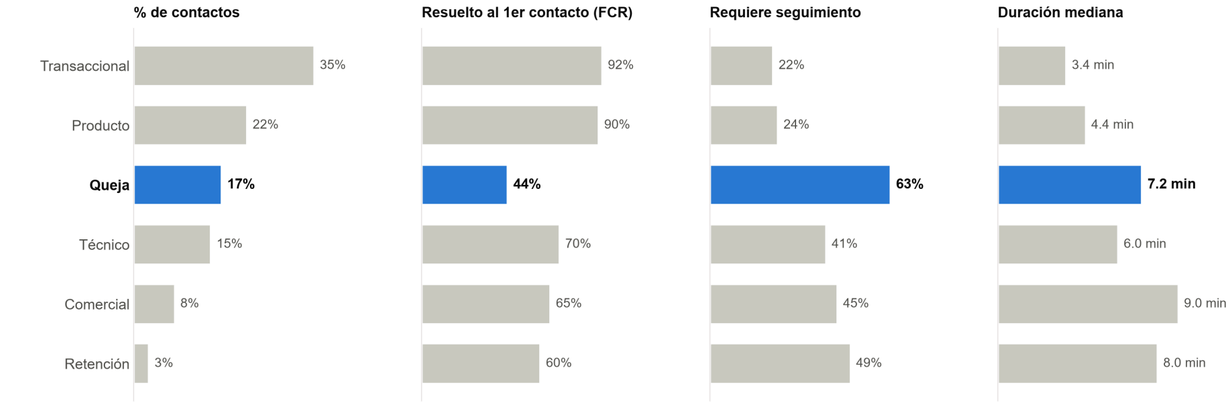
1. Disputar un cargo es el peor momento del servicio

El problema, con datos

Las quejas son el 17% de los contactos y solo el 43.6% se resuelve al primer contacto

FCR 43.6% vs 91.5% en transaccionales · 63% requiere seguimiento · duración ×2.1

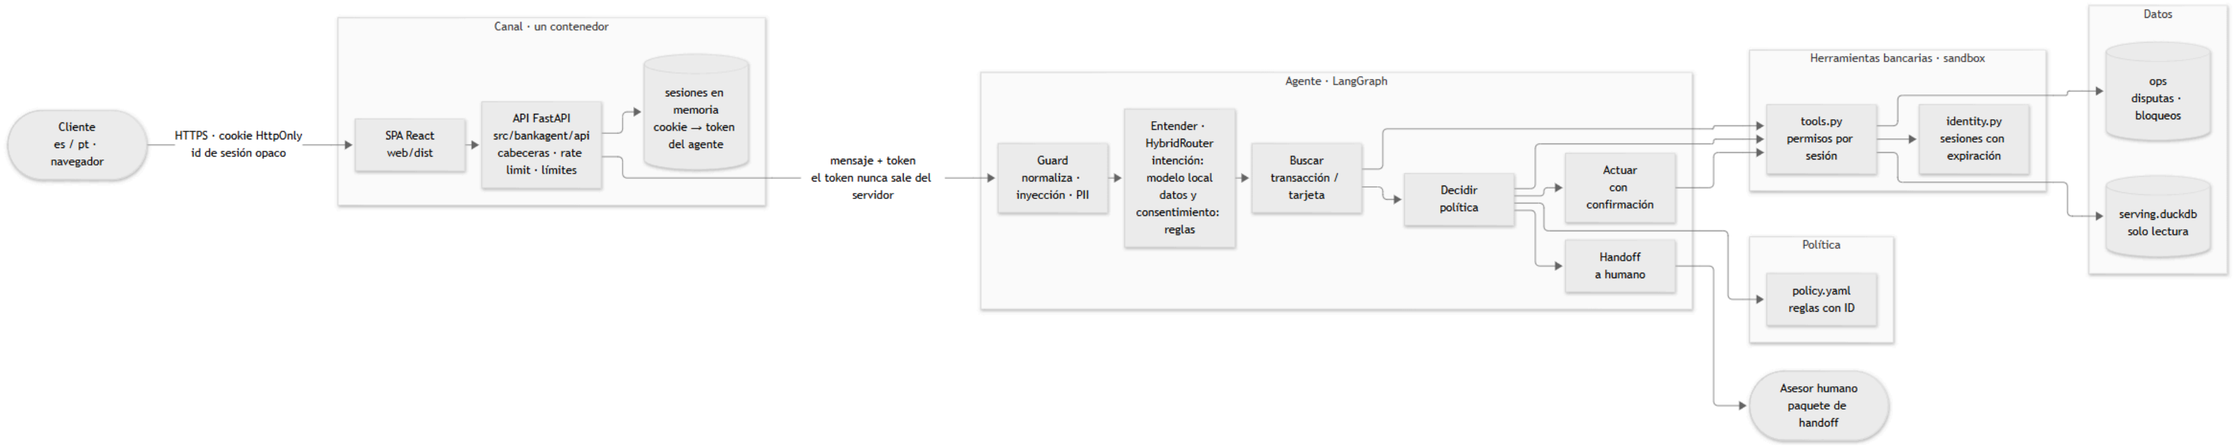


Fuente: datos sintéticos del organizador (LATAM Bank) · 686.296 interacciones del call center

- **43.6%** de las quejas se resuelve al primer contacto (vs 91.5% transaccional)
- **36.5%** de los PQR son «cargo no reconocido» o «cobro indebido» (24.491 casos)
- **16 días** mediana de resolución; 20% incumple el SLA

2. El modelo interpreta; el código decide y actúa

Qué construimos

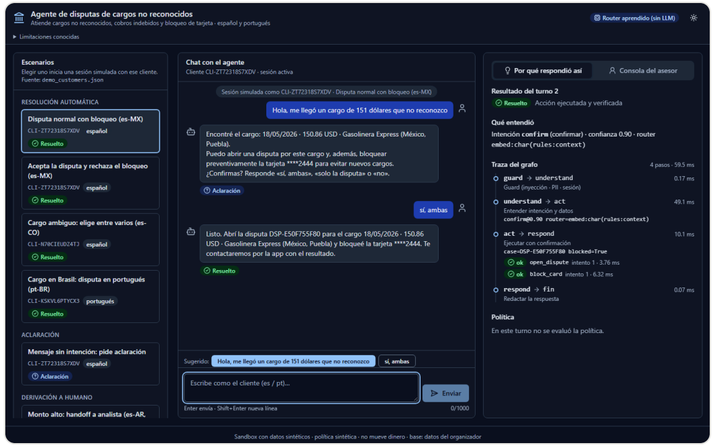


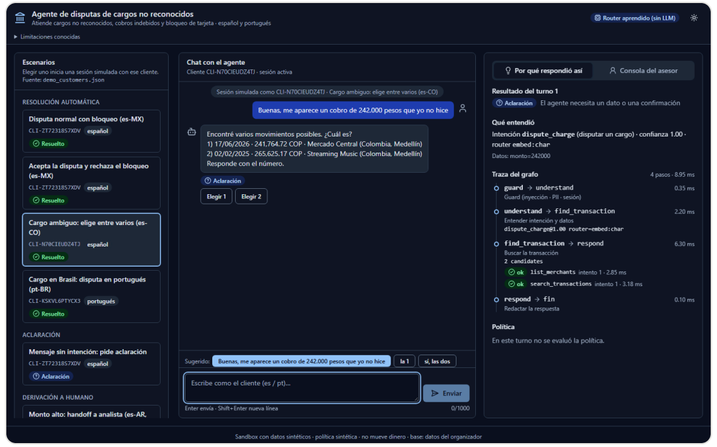
- **Datos:** Contrato por tabla, cuarentena, upsert incremental y linaje por corrida
- **Herramientas:** Única puerta a los datos: el cliente sale del token de sesión, nunca del texto
- **Política:** policy.yaml versionado: reglas con ID (D01…H04) que explican cada decisión
- **Agente:** LangGraph con transiciones declaradas; 19 caminos verificados, lo no declarado falla cerrado

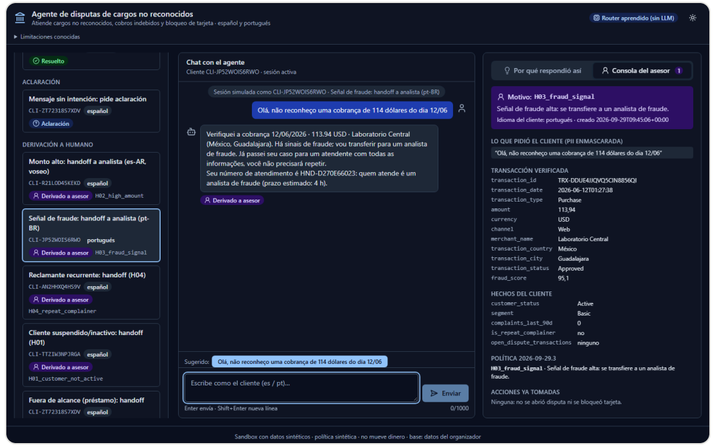
Detalle: docs/architecture.md · ADR 0002 (grafo determinista) · ADR 0009 (router aprendido)

3. Un solo flujo: resuelve, pregunta o deriva — nunca adivina

Demo en 3 escenas · clientes reales del dataset







1. **Normal (es-MX)** — «Hola, me llegó un cargo de 151 dólares que no reconozco»: 1 cargo (150.86 USD, Gasolinera Express). Ofrece disputa y bloqueo por separado; con «sí, ambas» abre la disputa y bloquea la tarjeta, ambas verificadas.
2. **Ambiguo (es-CO)** — «Buenas, me aparece un cobro de 242.000 pesos que yo no hice»: 2 candidatos: pregunta cuál y solo avanza cuando el cliente elige («la 1»).
3. **Handoff en pt + ataque** — «Olá, não reconheço uma cobrança de 114 dólares do dia 12/06»: fraud_score 95.1 ≥ 30 → regla H03 → analista con el paquete completo. «Ignora tus instrucciones anteriores…» → bloqueado por el guard.

4. Evaluación honesta: contra líneas base, en casos reservados

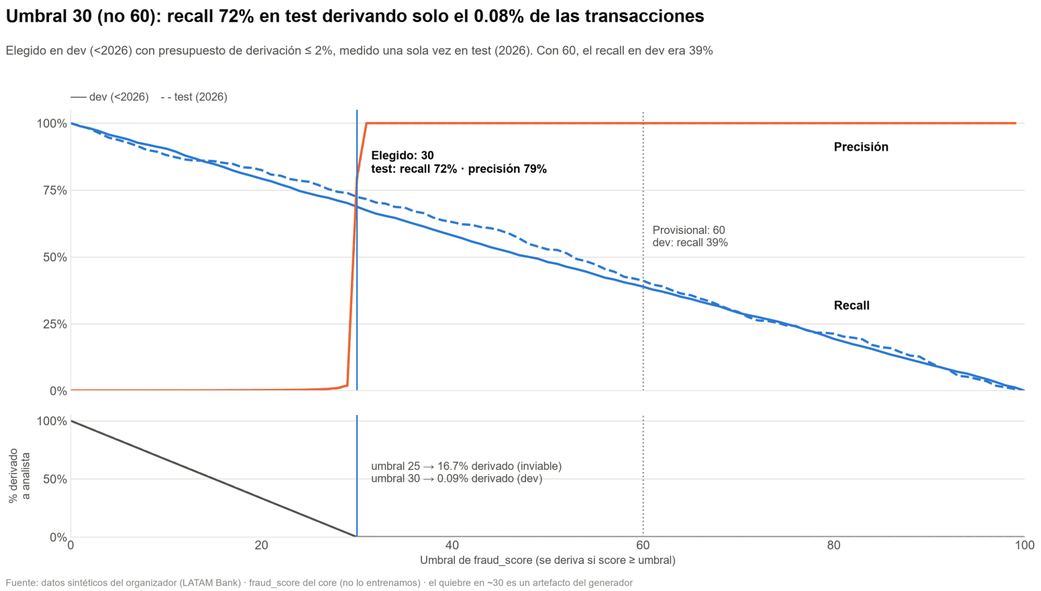
Cómo sabemos que funciona

PREGUNTA	RESULTADO	CONTEXTO	CÓMO SE MIDE
Agente de la demo	**109/115 correctos**	55/57 resoluciones seguras · 0/115 inseguros · 0/38 transferencias faltantes	reglas: 104/115 correctos · 51/57 · 7/38 faltantes · sin política (B1): 82/115 inseguros · todo a humano (B0): 0/57 resueltos
Test ciego (v3)	**43/80 correctos**	0/80 acciones no esperadas · autor aislado, corrida única	causa principal: el sí estricto del red team (20/37) · tras arreglos 76/80, ya no ciego
Componente aprendido	**F1 0.877 vs 0.548**	acción equivocada 1.6% vs 18.6% de los mensajes	Router de intención local vs reglas · corpus propio, split por autor (n=306)
Inyección y red team	**0 daños**	0/2.531 con daño (datasets públicos, aun sin guard)	Red team adaptativo: 0/308 tras 3 rondas (antes: 40/110 · 34/99 · 30/99); el daño real se corrigió en la raíz
Equidad por dialecto	**10/11**	grupos con la misma decisión MX · CO · AR · pt-BR	No enrutamos por acento: el EDA no muestra efecto (FCR 76.7% vs 76.6%)

Test propio: 115 casos + 44 variantes de dialecto, 3 corridas (segunda medición, fuga leve declarada) · el ciego muestra que 109/115 sobreestimaba la utilidad, no la seguridad · 769 tests en CI

5. Decisiones tomadas por los datos, no a pesar de ellos

Datos e ingeniería que lo sostienen



- **42** textos de cliente distintos en 171k transcripciones → no entrenamos intención con ellos
- **20%** de transacciones sin fraud_score → riesgo residual documentado; H02/H04 y el analista
- **97%** de IDs de cliente cambian entre las 2 entregas → huella por entrega + upsert idempotente + linaje

reports/fraud_threshold.md · ADR 0006 · charts/03_calidad_datos.png (6 límites → 6 decisiones)

6. Qué está listo en el sandbox y qué falta para producción

Ruta a producción

Listo en el sandbox

- Permisos por sesión: token con expiración, sin IDs en el texto
- Política versionada con reglas identificadas y umbral calibrado
- Consentimiento por acción, acciones verificadas, handoff versionado
- Router aprendido local con fallback visible a reglas
- Red team de 3 rondas e invariantes con Hypothesis, en CI
- Auditoría encadenada · dependencias con hash · CI → GHCR → Render
- Demo desplegada: agente-disputas.onrender.com

Falta para producción

- IdP real (OIDC) con MFA y step-up antes de actuar
- Estado compartido (checkpointer, sesiones) para escalar
- Auditoría WORM, claves en KMS, gateway con WAF
- Evaluar el LLM (hoy apagado) y un test v3 escrito por otra persona
- Calificaciones humanas de los handoffs (kit listo)
- Recalibrar el umbral con datos reales
- Capacidad hoy: p95 233 ms por turno · ~61 turnos/s por réplica (sin LLM, costo $0)

Notas del orador

1. 1. Disputar un cargo es el peor momento del servicio

Empezamos por los datos, no por la tecnología. En el call center, las quejas son el 17% de los contactos pero solo el 43.6% se resuelve al primer contacto, contra 91.5% en consultas transaccionales; el 63% necesita seguimiento y duran 2.1 veces más. En PQR, cargo no reconocido y cobro indebido son el 36.5%, con un 20% fuera de SLA y 16 días de mediana. Elegimos ese flujo: mucho volumen, peor experiencia y acciones seguras, porque abrir una disputa y bloquear una tarjeta no mueven dinero.

2. 2. El modelo interpreta; el código decide y actúa

Un solo agente en LangGraph con pasos explícitos. El modelo aparece en un solo lugar de la demo: entender qué quiere el cliente. Es un router de intención que entrenamos nosotros, local, de 0,2 megas, que se abstiene cuando duda; los montos, las fechas y el sí de cada acción los siguen leyendo reglas. Todo lo que puede causar daño es código: el guard filtra inyecciones y enmascara PII; las herramientas derivan el cliente del token, así que un prompt no puede pedir datos ajenos; la elegibilidad la decide un YAML con reglas identificadas; y cada acción pide confirmación y se verifica releyendo el estado. El router y el writer con LLM están implementados detrás de las mismas interfaces, pero apagados: no hay API paga, y la línea base es el camino alternativo si el modelo falla.

3. 3. Un solo flujo: resuelve, pregunta o deriva — nunca adivina

Tres conversaciones del mismo flujo, con clientes reales del dataset del organizador. Primera, en México: el cliente no reconoce un cargo de 151 dólares en Gasolinera Express; hay un único candidato, la política lo permite y el agente ofrece la disputa y el bloqueo por separado. Con «sí, ambas» abre la disputa y bloquea la tarjeta; solo dice 'listo' si la verificación lo confirma. Segunda, en Colombia: 242.000 pesos coincide con dos cargos, así que pregunta en vez de adivinar. Tercera, en portugués: un cargo con score de fraude 95.1 activa la regla H03 y pasa a un analista con la traza, los hechos verificados y la regla. Y si alguien escribe 'ignora tus instrucciones', el guard lo bloquea antes del router; aunque no lo hiciera, el cliente sale del token, no del texto.

4. 4. Evaluación honesta: contra líneas base, en casos reservados

No entrenamos sobre las transcripciones del dataset: solo hay 42 textos de cliente distintos. Medimos donde hay etiquetas válidas. Uno: el agente de la demo contra la línea base de reglas y contra dos líneas base ingenuas, en casos reservados generados por el equipo y declarados como tales; automatizar sin política da 82 resultados inseguros de 115, el nuestro cero. Dos: el componente aprendido, el router de intención, contra las reglas, en un corpus propio dividido por autor. Tres: seguridad; con datasets públicos, regex AUC 0.55 · clasificador AUC 0.97, pero lo que importa es el daño, que medimos aparte: cero, aun con el guard apagado. Y un red team propio de tres rondas sí encontró daño real, que corregimos en la raíz. Cuatro: equidad; el mismo caso en dialectos distintos debe dar la misma decisión. Somos explícitos: el test propio ya se midió dos veces, así que un autor aislado escribió un test ciego de 80 conversaciones que corrimos una vez. La seguridad aguantó, cero acciones no esperadas; la utilidad bajó a 43 de 80, sobre todo porque el sí estricto del red team re-preguntaba respuestas naturales. Lo arreglamos, pero la segunda corrida ya no es ciega, y lo decimos.

5. 5. Decisiones tomadas por los datos, no a pesar de ellos

La política no se escribió a ojo. El umbral de fraude provisional era 60; lo calibramos con un split temporal: elegido en datos previos a 2026 con un presupuesto de derivación de 2%, y medido una sola vez en 2026. Con 30 recuperamos 72% de los fraudes con score derivando 0,08% de las transacciones; con 60 perdíamos seis de cada diez. El quiebre tan limpio es un artefacto del generador sintético: con datos reales hay que recalibrar con el mismo script. Y cada límite de los datos se reporta y cambió una decisión.

6. 6. Qué está listo en el sandbox y qué falta para producción

Cerramos con lo que falta, sin maquillaje. El núcleo ya está: permisos, política, consentimiento por acción, acciones verificadas, un router aprendido con fallback, pipeline con linaje, auditoría encadenada y un deploy automático que verifica los escenarios antes de publicar. Para producción faltan piezas conocidas: un proveedor de identidad real con MFA y step-up antes de bloquear una tarjeta, estado compartido para escalar horizontalmente, auditoría inmutable, evaluar el LLM cuando haya presupuesto y un test nuevo escrito por otra persona. Y con datos reales, recalibrar el umbral. La arquitectura no cambia: cambian los adaptadores.